

可信公告事件提取与跨文档核验智能体 项目计划书

参赛方向：数据结构化提取

参赛单位：北京林业大学 信息学院（人工智能学院）

团队成员：魏文字、张智博、宗博文、方轩诚、陈家浩

指导老师：范新

2026 年 9 月

一、项目概述

1. 本项目做一件事：从非标准化公告、扫描件和复杂表格中，提取质押、中标、股权变动等事件字段，每个字段带原文出处，并在多份公告之间核对同一事件的数值矛盾（对应选题方向一“数据结构化提取”）。
2. 系统由两条工作流串成：工作流 A 处理单份公告，输出结构化事件记录；工作流 B 把同一事件的全部公告对齐比较，输出矛盾清单与核验报告。
3. 设计重心不在语义理解，而在让机器读出的每个数字可以核验、每次运行结果一致。
4. 运行底座用 deepseek harness 框架，模型用 DeepSeek 系列等，事件提取的各环节以插件形式自行开发。
5. 交付形态：网页界面加命令行入口，核心流程可离线运行。

二、背景与问题

1. 公告材料不规范。同样是质押比例，有的公告写“占其所持股份比例的 43.2%”，有的写“占公司总股本的 1.80%”，两个数经常在同一张表的相邻单元格里，抄错一格结论方向就反了；历史公告还有大量扫描件，没有文本层。
2. 人工提取错误率高。一份公告读十分钟，读到第一百份时疲劳漏字段几乎必然；单位换算是事故高发区，把“1.2 亿元”录成“12,000 元”并不罕见；数字通常不留出处，三个月后有人质疑，得重新翻一遍原始文件。
3. 跨文档矛盾没人核验。首次公告写质押 500 万股，半年后进展公告写累计 800 万股，这 300 万股的差额可能是补充质押、披露笔误或漏读了公告，单看任何一份文件都发现不了。

三、系统设计

1. 总体分三层：底层是共享核心（PDF 解析、扫描件 OCR 双通道、表格结构还原、数值标准化、出处定位）；中间是智能体框架层（编排、工具调用、日志）；上层是事件提取插件（工作流 A 与 B）。

2. 工作流 A（单份公告提取）：

（1）每类事件定义必填字段清单。质押：出质人、质权人、质押股数、占其所持股份比例、占总股本比例、质押起止日、单次与累计；中标：金额、对手方、工期、是否联合体、是否关联交易；股权变动：变动主体、方式、变动前后持股比例、是否跨越 5% 举牌线或 30% 要约收购线。

（2）字段确实不存在的，标注“原文未提及”，不猜也不留空。

3. 工作流 B（跨文档核验）先归因后定级：数值不同先查能否用单位、币种、单次与累计、含税与不含税、比例基准等口径差异解释，能解释的单独归类呈现，解释不了的才判矛盾；对真矛盾并排展示双方取值与出处，不替用户裁决。

4. 扫描件与复杂表格：文本层 PDF 直接解析；扫描件走双通道（系统原生离线 OCR 加视觉大模型直读），任一通道可用即可工作，不依赖 GPU；表格单独处理并定位到具体单元格，还原失败时触发独立复核通道并降级为区域级出处。

5. 框架选型三条硬标准：支持插件与工具注册；自带完整调用日志（文件访问、工具调用、计算过程逐条留痕）；支持封闭环境运行（输入只读、工作区白名单、网络出口白名单）。不满足任何一条直接排除；入选后在提交材料中列明名称、版本、许可证及使用范围，不冒充自主开发。

四、可信性设计

1. 模型只找数、不算数。“500 万股”换算成 5,000,000、“43.2%”换算成 0.432、质押股数除以持股总数验证比例，这些运算全部由确定性程序完成，用十进制精确计算避免浮点误差。数值准确性由此从概率问题变成工程问题：只有定位环节依赖模型，错误来源可以逐类测试。

2. 出处随数据生成。每个字段带四级出处（文件、页码、页面区域、表格行列），在解析阶段生成、随数据传递，不事后回原文搜索——同一数字在公告里经常出现多次，事后搜索给出的出处很可能是错的，而错误的出处会让人误以为已经核

对过。界面上点击任意数字，右侧打开原文并高亮；导出报告为每个字段附文件名、页码和原文片段。

3. 同输入同输出。固定模型参数、锁定依赖版本、对模型调用结果做缓存，同一份文件重复运行输出逐字段一致；同时提供清空缓存重跑开关，主动展示模型不确定性会造成哪些字段漂移。

4. 错误填充率单独监控。在抽取准确率之外，把“原文没有、系统却给出一个值”的比例单列为一级指标，它直接度量幻觉的危害；评测集专门构造字段缺失样本考核这一项。

五、与现有做法的对比

1. 通用大模型直接抽取：语义理解强，但会自己算数且算错、无出处、不分单次与累计口径、过程不可复现。

2. 传统 OCR 加规则模板：数值准确，但模板一变就失效，覆盖面窄，事后搜索出处同值多处出现时会指错。

3. 云端通用文档解析：适应力强，但需上传云端（金融数据保密风险），过程黑箱不可复现，无跨文档核验。

4. 本项目：计算全程序化、四级出处定位到单元格、口径作为数据字段建模、有跨文档矛盾分级、本地留痕加重放命令、核心链路离线。

六、实施计划

1. 总体节奏：初赛（10月18日）前三类事件全量做完整，评测跑出真实数字，网页原型可用；初赛后至决赛（11月底）用真实公告扩充评测集，补强扫描件能力，打磨可复现性与现场演示。

2. 第1周（9/22-9/28）：框架选型冻结、数据标准定稿；合成数据生成器可跑，端到端空流程贯通。

3. 第2周（9/29-10/5）： workflow A 达标；单份公告输出完整结构化记录，字段均可回溯原文。

4. 第3周（10/6-10/12）： workflow B 达标；多份公告输出矛盾清单与核验报告，重放命令可用。

5. 第4周（10/13–10/17）：10/14 全量评测出数，10/15 计划书定稿，10/16 视频，10/17 提交；周内预留两天追赶窗口。
6. 决赛阶段（10/19–11/25）：真实公告扩充评测集与标注，扫描件双通道调优，离线演示模式与现场未预处理样例，答辩准备。
7. 分工：魏文字（队长）——总体架构、智能体框架与插件接口；张智博——文档解析与表格还原（含扫描件双通道）；宗博文——评测集独立维护与全量评测，不参与开发；方轩诚——跨文档对齐与矛盾归因规则库；陈家浩——网页界面、演示环境与视频。
8. 协作机制：每周日晚核对完成判据而非“做完了吗”；代码走分支加评审；评测标准由宗博文独立维护，开发人员不得修改，降低自己出题自己答的自评偏差。

七、数据来源与合规

1. 前期用合成数据：自研生成器按可控难度维度（扫描件、跨页表格、单位变异、字段缺失）批量生成，标准答案同步产出，零标注成本。
2. 后期用公开披露的 A 股公告，分层抽样人工标注，校准合成数据与真实分布的差距。检索后未发现公开的中文 A 股公告表格结构标注数据集，评测集需自建，如实说明。
3. 合规边界：仅用依法公开披露信息；遵守站点使用条款，严格限速；不二次分发原始文件，评测集对外仅提供文档索引与标注结果；不用内幕与隐私数据；回避 AGPL 类组件；代码库不含密钥；系统不输出投资建议。

八、风险与应对

1. 进度延期：启用追赶缓冲；必要时裁剪范围，优先保质押与股权变动两类事件做深做透，中标事件与扫描件降为实验性。
2. 扫描件识别不达预期：双通道交叉校验；仍不达标则标注低置信度并附区域截图交人工，如实说明其为辅助能力。
3. 表格还原失败：触发独立复核通道（视觉模型直读表格区域），降级为区域级出处。
4. 大模型输出不稳定：固定参数加结果缓存；提高规则通道与表格通道权重，降低模型依赖度。

5. 数据标准后期变更：第 1 周冻结标准，后续变更仅允许新增可选字段。
6. 现场演示失败：核心链路离线可跑，准备离线演示模式与现场临时提供的未预处理公告。

九、预期成果与考核指标

1. 交付物：项目计划书与介绍视频；可运行的系统原型（网页与命令行）；完整源代码、依赖清单与运行说明；公告事件统一数据标准、合成数据生成器、口径规则库。
2. 字段抽取准确率 $\geq 90\%$ （抽出的字段基本可用）。
3. 数值标准化准确率 $\geq 98\%$ （单位换算不出错）。
4. 错误填充率 $\leq 5\%$ （原文没有却编出值的比例，单独监控）。
5. 输出格式合规率 100%（下游可直接入库）。
6. 出处定位命中率 $\geq 95\%$ （点开就能看到原文）。
7. 矛盾检出召回率 $\geq 85\%$ ，矛盾误报率 $\leq 10\%$ （该发现的不放过、不淹没用户）。
8. 重复运行字段一致率 $\geq 98\%$ （可入库、可回测）。
9. 单份 20 页公告处理耗时 ≤ 90 秒（现场演示可用）。

十、局限说明

1. 不做模型微调：能力上限受基础模型制约，这是工期约束下的主动选择。
2. 合成数据只能证明受控条件下的能力边界，与真实分布的差距用真实集单独报告。
3. 扫描件识别是辅助能力，极模糊条件下输出未知交人工。
4. 只覆盖质押、中标、股权变动三类事件，不承诺扩展到全部公告类型。
5. 系统输出事实与测算，不输出投资建议；在金融数据场景里，说清楚系统不能做什么，与展示它能做什么同等重要。